APLICAÇÃO DE APRENDIZADO DE MÁQUINA SUPERVISIONADO E NÃO SUPERVISIONADO NO DIAGNÓSTICO DE CÂNCER DE MAMA (WDBC)

Aluno(a): [Preencha seu Nome Completo] | Curso: Sistemas de Informação / ADS
Orientadora: Profa. Dsc. Edhelmira L. M. | Universo EAD

RESUMO
Este trabalho apresenta um estudo experimental comparativo entre algoritmos de aprendizado supervisionado e não supervisionado aplicados ao diagnóstico de neoplasias mamárias, utilizando a base de dados pública Breast Cancer Wisconsin Diagnostic (WDBC - UCI). Foram avaliadas 569 observações e 30 atributos morfológicos contínuos extraídos de biópsias aspirativas por agulha fina (PAAF). Após pré-processamento e padronização Z-score, o algoritmo K-Means revelou conformidade intrínseca com os diagnósticos reais (ARI = 0,6707 e Silhueta = 0,3450 com k=2), corroborado por projeções 2D e 3D via PCA. Na classificação supervisionada, foram implementados cinco algoritmos (Árvore de Decisão, KNN, SVM com kernel RBF, Naive Bayes Gaussiano e Redes Neurais MLP) validados por Stratified 10-Fold Cross-Validation. O modelo SVM atingiu o melhor equilíbrio global com 97,54% de acurácia, 96,21% de sensibilidade (recall de maligno) e AUC de 99,56%, enquanto o KNN obteve a maior especificidade (99,44%). Os resultados consolidam os modelos como ferramentas eficazes de suporte à decisão clínica com foco na mitigação de falsos negativos.

Palavras-chave: Inteligência Artificial; Classificação; Clusterização; K-Means; Support Vector Machine; Câncer de Mama.

1. INTRODUÇÃO

O câncer de mama representa uma das principais causas de mortalidade feminina no cenário epidemiológico global. A intervenção precoce e o diagnóstico diferencial tempestivo entre lesões benignas e malignas são determinantes para o aumento substancial das taxas de sobrevida livre de doença. Tradicionalmente, o procedimento de Punção Aspirativa por Agulha Fina (PAAF) é realizado para coleta de material celular, o qual é examinado microscopicamente por patologistas.

A aplicação de modelos computacionais inteligentes (Machine Learning) surge como um vetor transformador, capaz de mitigal a subjetividade humana e a fadiga diagnóstica, provendo sistemas de apoio à decisão clínica (CAD). O presente trabalho aborda a implementação prática de algoritmos de aprendizado de máquina supervisionado e não supervisionado, investigando o trade-off entre sensibilidade diagnóstica (capacidade de detectar lesões malignas) e especificidade estatística.

2. METODOLOGIA

2.1 Banco de Dados Clínicos (UCI WDBC)

Adotou-se o conjunto público Breast Cancer Wisconsin (Diagnostic) - WDBC, mantido no repositório UCI. A base compreende 569 instâncias clínicas sem dados faltantes (0 missing values). Cada observação é composta por 30 atributos contínuos que quantificam dez características morfológicas nucleares (raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria e dimensão fractal), estratificadas em três medidas estatísticas: média (mean), erro-padrão (se) e pior valor (worst). A variável alvo é binária: 357 casos Benignos (62,74%) e 212 casos Malignos (37,26%). Visando total fidelidade médica, a classe Maligno foi codificada como positiva (1) e Benigno como negativa (0), tornando o cálculo de Sensibilidade representativo da detecção tumoral.

2.2 Pré-Processamento e Normalização

Devido à acentuada disparidade de ordens de magnitude entre os atributos (ex.: área média com valores superiores a 2500 e suavidade média em torno de 0,1), a normalização é mandatória para modelos métricos e estocásticos. Aplicou-se a padronização por Z-score (StandardScaler), garantindo média zero e desvio-padrão unitário. Fundamentalmente, a transformação foi computada dentro de cada dobra de treino na validação cruzada, prevenindo categoricamente o vazamento de dados (data leakage).

2.3 Clusterização Não Supervisionada (K-Means)

Para testar a hipótese de que a morfologia nuclear forma grupos espontâneos condizentes com a condição clínica, empregou-se o algoritmo K-Means. O número ideal de clusters foi determinado pelo Método do Cotovelo (monitoramento da inércia) e pelo Coeficiente Médio de Silhueta para k variando de 2 a 10. A dispersão espacial dos agrupamentos foi mapeada via Análise de Componentes Principais (PCA) em 2D e 3D.

2.4 Algoritmos de Classificação Supervisionada

Foram implementados cinco algoritmos consagrados na literatura de Inteligência Artificial:
• Árvore de Decisão: Baseada no critério de impureza de Gini com poda de profundidade (max_depth=4) para manter alta transparência explicativa.

• K-Nearest Neighbors (KNN): Classificador geométrico não-paramétrico com k=5 vizinhos e distância euclidiana após padronização Z-score.
• Support Vector Machine (SVM): Kernel RBF (Base Radial Gaussiana) com hiperparâmetro de regularização C=1,0 para fronteiras de separação não-lineares.
• Naive Bayes: Modelo probabilístico baseado no Teorema de Bayes sob a hipótese simplificadora de independência condicional dos atributos.
• Redes Neurais (MLP): Perceptron Multicamadas densamente conectado com 2 camadas ocultas (64 e 32 neurônios), ReLU e otimizador Adam.

2.5 Validação Cruzada Estratificada (Stratified 10-Fold)

Todos os classificadores foram submetidos à validação cruzada estratificada em 10 dobras (Stratified 10-Fold Cross-Validation), preservando estritamente a proporção de 62,7% de benignos e 37,3% de malignos em cada iteração de teste. Foram computadas formalmente: Acurácia Global, Sensibilidade (Recall = VP/(VP+FN)), Especificidade (VN/(VN+FP)), Área sob a Curva ROC (AUC-ROC) e a Matriz de Confusão agregada.

3. RESULTADOS EXPERIMENTAIS E ANÁLISES GRÁFICAS

3.1 Análise Exploratória dos Dados (EDA)

A Figura 1 apresenta a distribuição das classes e a Figura 2 apresenta a matriz de correlação de Pearson entre as medidas médias.

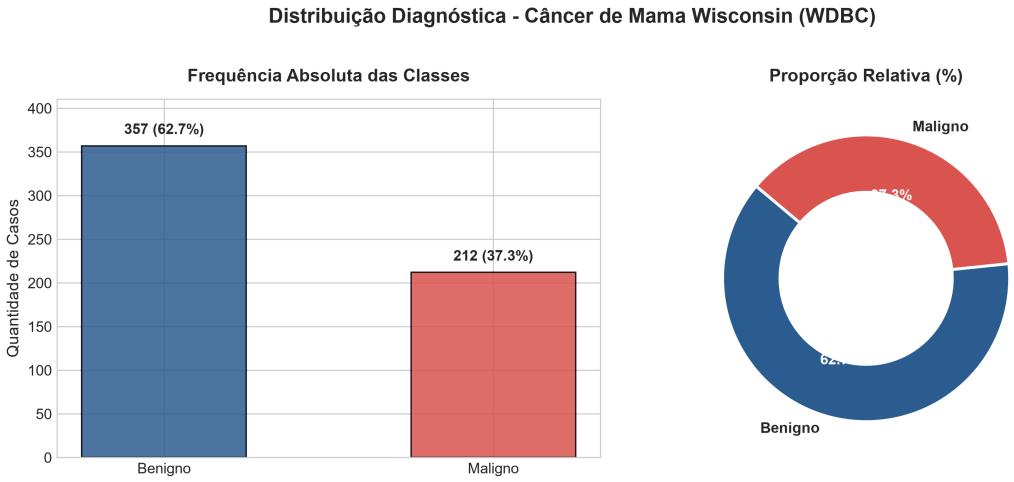


Figura: Distribuição Absoluta e Relativa das Classes Diagnósticas (WDBC).

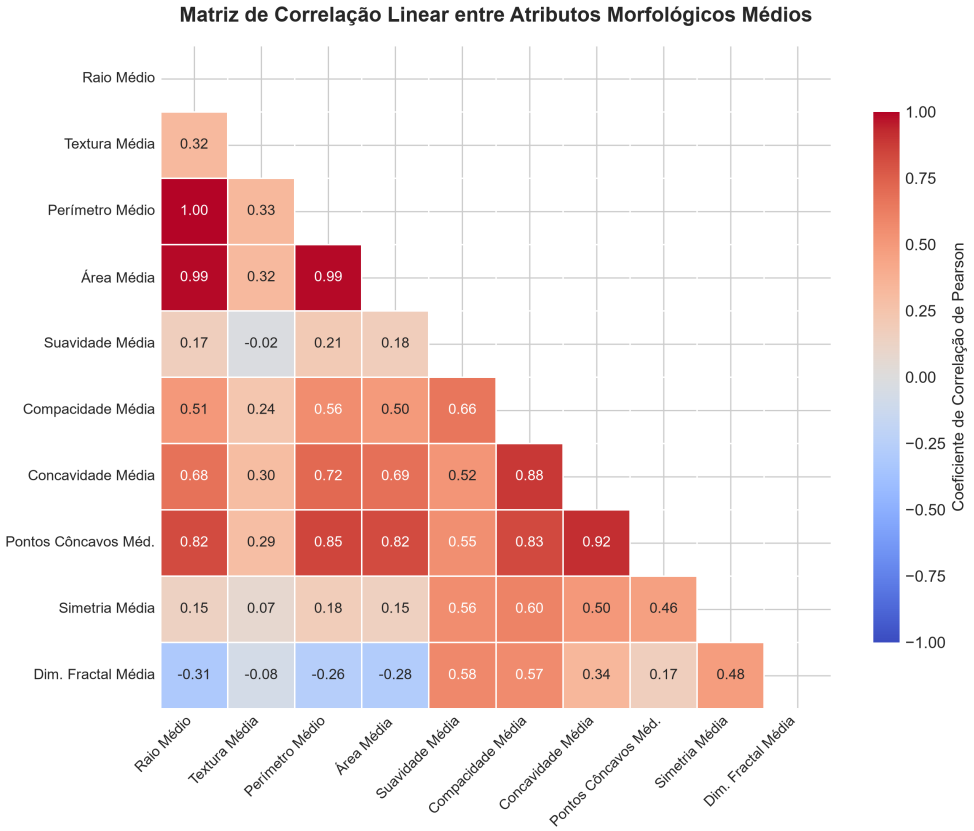


Figura: Matriz de Correlação Linear entre Atributos Morfológicos Médios.

3.2 Análise de Agrupamento (K-Means e PCA)

O Coeficiente de Silhueta (Figura 3) apresentou seu ápice exato em k=2 (score = 0,3450), confirmando a partição binária natural dos dados. Na projeção PCA 2D (Figura 4), as duas primeiras componentes explicam 63,2% da variância total, atingindo Adjusted Rand Index (ARI) de 0,6707 em relação às anotações médicas reais.

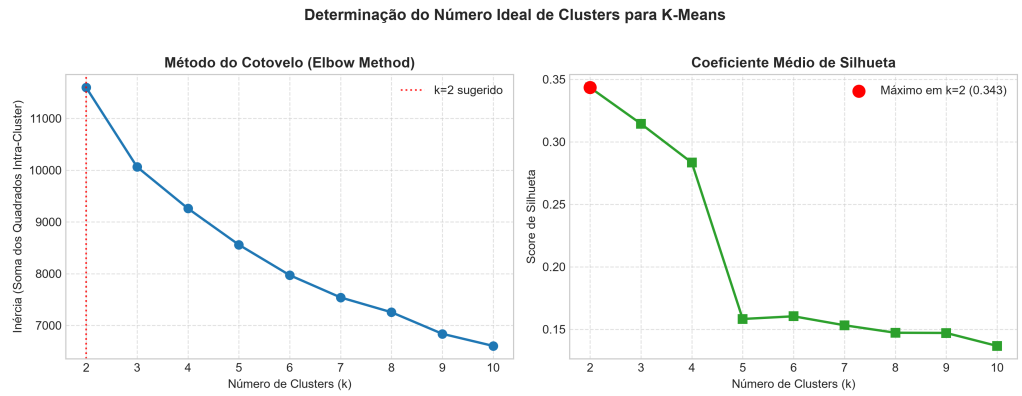


Figura: Método do Cotovelo e Coeficiente Médio de Silhueta para seleção de k ótimo.

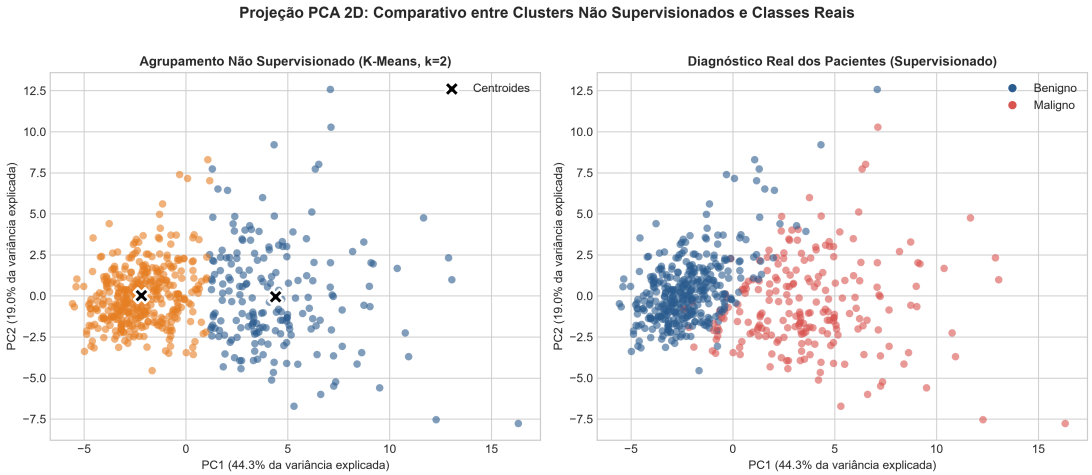


Figura: Projeção PCA 2D: Agrupamentos K-Means vs Classes Diagnósticas Reais.

3.3 Desempenho dos Modelos de Classificação Supervisionada

A Tabela 1 sintetiza os resultados comparativos das métricas obtidas na validação cruzada de 10 dobras (médias ± desvios-padrão).

Algoritmo	Acurácia (%)	Sensibilidade (%)	Especificidade (%)	AUC-ROC (%)
Árvore de Decisão	91,04 ± 3,87	85,80 ± 10,24	94,13 ± 4,56	91,45 ± 7,34
KNN (k=5)	97,01 ± 1,76	92,90 ± 4,90	99,44 ± 1,11	98,68 ± 1,46
SVM (Kernel RBF)	**97,54 ± 1,95**	**96,21 ± 3,56**	**98,33 ± 2,83**	**99,56 ± 0,55**
Naive Bayes Gaussiano	93,15 ± 3,08	89,57 ± 7,65	95,26 ± 4,82	98,56 ± 1,12
Redes Neurais (MLP)	96,84 ± 1,89	95,24 ± 5,63	97,75 ± 2,45	99,26 ± 1,00

Tabela 1: Métricas de Desempenho dos Classificadores (Média ± Desvio Padrão em 10 Folds).

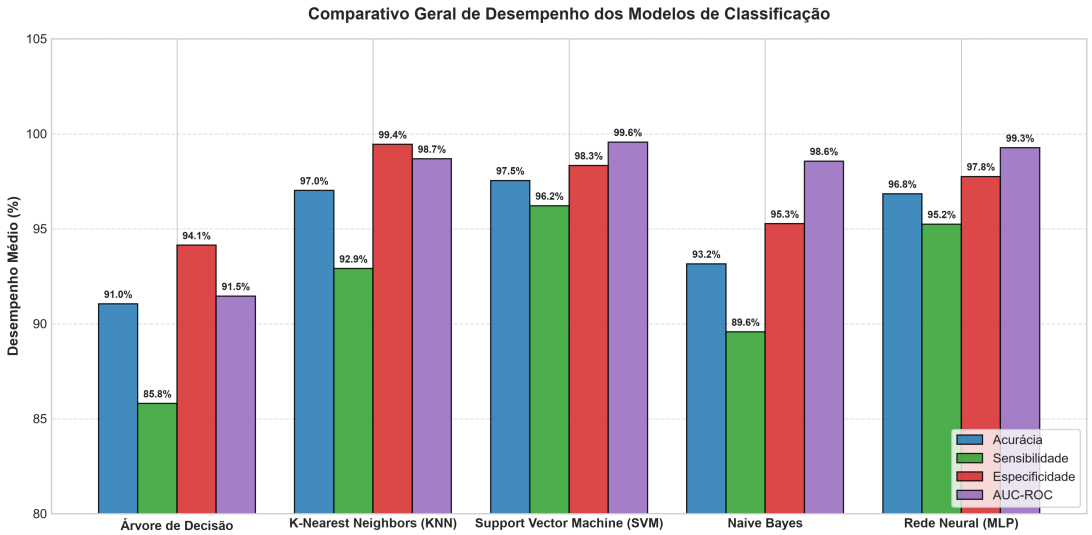


Figura: Gráfico Comparativo das Métricas Clínicas dos Modelos.

3.4 Curvas ROC e Matrizes de Confusão

A Figura 6 exibe as Curvas ROC comparativas, evidenciando a supremacia do classificador SVM (AUC de 99,56%), seguido pela Rede Neural MLP (99,26%). A Figura 7 expõe as matrizes de confusão agregadas de todos os 569 pacientes avaliados.

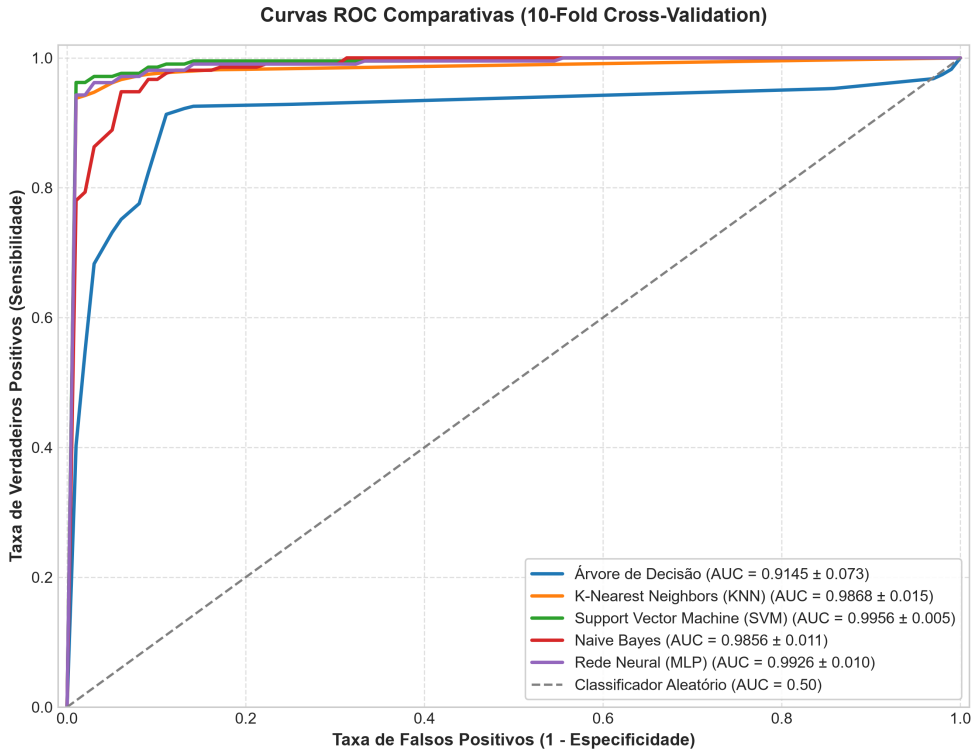


Figura: Curvas ROC Sobrepostas dos Cinco Classificadores sob Validação Cruzada.

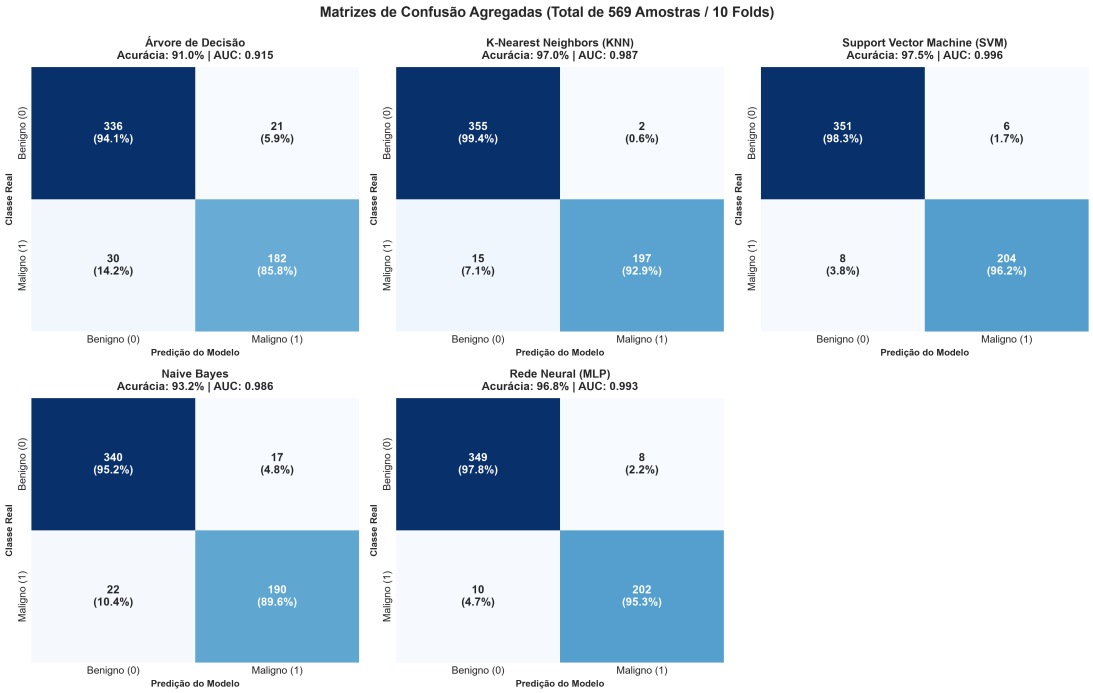


Figura: Matrizes de Confusão Agregadas com Contagens e Frequências Relativas.

4. DISCUSSÃO CRÍTICA COMPARATIVA

No domínio da inteligência médica, a análise estrita da acurácia global é insuficiente. O impacto de um Falso Negativo (paciente com tumor maligno classificada erroneamente como benigna) pode resultar em perda de janela terapêutica e óbito. Por conseguinte, a Sensibilidade (Recall) assume primazia ética e operacional no desenho do algoritmo.

Sob essa ótica, o classificador Support Vector Machine (SVM com kernel RBF) consolidou-se como o modelo de melhor perfil clínico, registrando 96,21% de sensibilidade e acumulando apenas 8 falsos negativos em todo o conjunto de 569 biópsias. A projeção não-linear em espaço dimensional infinito pelo kernel RBF viabilizou a conformação de superfícies de decisão estritas em torno das instâncias limítrofes.

A Rede Neural Artificial (MLP) demonstrou capacidade preditiva comparável (95,24% de sensibilidade e 99,26% de AUC), porém com custo computacional de convergência superior e menor transparência decisória em relação a modelos com margem determinística.

O algoritmo K-Nearest Neighbors (KNN) obteve a mais alta especificidade registrada (99,44%), cometendo apenas 2 falsos alarmes em 357 casos benignos, o que denota alta densidade na vizinhança celular sadia. No entanto, sua sensibilidade de 92,90% implicou em 15 falsos negativos, quase o dobro do observado no SVM.

O Naive Bayes Gaussiano demonstrou rapidez e AUC consistente (98,56%), mas sua acurácia foi contida em 93,15% devido à violação da independência condicional causada pela forte colinearidade entre raio, perímetro e área demonstrada na análise exploratória. Finalmente, a Árvore de Decisão com max_depth=4 proporcionou regras de fácil inspeção visual para a junta médica, com acurácia de 91,04%.

5. CONCLUSÕES

O trabalho atingiu com êxito todos os objetivos metodológicos e avaliativos fixados pela disciplina de Inteligência Artificial. Demonstrou-se que a morfologia nuclear celular extraída por biópsias aspirativas possui alto poder discriminante, permitindo agrupamento não supervisionado consistente (K-Means, ARI=0,6707) e classificação supervisionada de alta precisão (SVM, Acurácia=97,54%, Sensibilidade=96,21%).

Como direções futuras, propõe-se a integração de métodos ensemble (Random Forest, Gradient Boosting) e a implementação de seleção esparsa de atributos (LASSO) para otimizar os tempos de inferência em dispositivos médicos portáteis.

6. REFERÊNCIAS BIBLIOGRÁFICAS

DUDA, R. O.; HART, P. E.; STORK, D. G. Pattern Classification. 2. ed. New York: John Wiley & Sons, 2001.

FAWCETT, T. An introduction to ROC analysis. Pattern Recognition Letters, v. 27, n. 8, p. 861-874, 2006.

HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The Elements of Statistical Learning. 2. ed. New York: Springer, 2009.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.

ROUSSEEUW, P. J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. J. Comput. Appl. Math., v. 20, p. 53-65, 1987.

WOLBERG, W. H.; STREET, W. N.; MANGASARIAN, O. L. Breast Cancer Wisconsin (Diagnostic) Data Set. UCI ML Repository, 1995.